

Tener contexto no significa *tener respuesta.*

Contexto suficiente: una nueva mirada a los sistemas de
generación aumentada por recuperación

Hailey Joren · Jianyi Zhang · Chun-Sung Ferng
Da-Cheng Juan · Ankur Taly · Cyrus Rashtchian · ICLR 2025

Cuando no basta con lo que recordamos

01

Memoria propia

Lo que ya sabemos



02

Fuentes externas

Encarta / Wikipedia

Stack Overflow

Artículos / documentación



03

Mejor respuesta

Lo que podemos construir

Consultar fuentes amplía lo disponible *en ese momento*.

RAG agrega contexto *en inferencia*



Los pesos del modelo **no cambian**.

Los documentos entran en las instrucciones del modelo

PREGUNTA DEL USUARIO

¿En qué país nació el autor de *Cien años de soledad*?

Consulta de fuentes →

ENTRADA DEL MODELO

Pregunta + contexto recuperado

«Gabriel García Márquez, autor de *Cien años de soledad*, nació en Colombia».

RESPUESTA

Colombia

Más contexto no elimina los errores

01

Responde mal

Incluso con evidencia
recuperada

02

Se distrae

Con información
no relacionada

03

No extrae el dato

Desde textos largos

Relevante no siempre significa *suficiente*

Ruido · relevancia · robustez · alucinaciones

Relacionado
con el tema

Contiene evidencia
para responder

La pregunta pendiente: **¿la información alcanzaba?**

¿El contexto alcanza
para construir una respuesta?

$(Q, C) \rightarrow$ existe una respuesta plausible A'

 Q

Pregunta

 C

Contexto disponible

 A'

Respuesta apoyada en C

Suficiente $\neq$ verdadero. El contexto también puede estar equivocado.

Hablar del tema no alcanza

¿En qué ciudad nació Ana?

INSUFICIENTE

Ana vive en Valparaíso.
Su madre nació en Santiago.

SUFICIENTE

Ana nació en
Concepción.

La suficiencia también exige desambiguar

$$A \rightarrow B \rightarrow C$$

Conectar hechos

Sin inventar enlaces

$$Q \rightarrow Q_1 / Q_2$$

Precisar la pregunta

Distinguir referentes

$$C \rightarrow A_1 / A_2$$

Distinguir respuestas

Resolver alternativas

Un juez para pregunta + contexto

Pregunta
+
Contexto



EVALUADOR AUTOMÁTICO

¿Alcanza?



Suficiente

Insuficiente

No recibe la respuesta oficial.

Primero lo comparan contra humanos


93,0%

Exactitud al clasificar
suficiencia

115 casos etiquetados
por humanos

Método	Exactitud	Sin respuesta oficial
Gemini 1.5 Pro · 1 ejemplo	93,0%	Sí
Gemini 1.5 Pro · sin ejemplo	87,0%	Sí
FLAMe	87,8%	Sí
TRUE-NLI	82,6%	No
Coincidencia literal	80,9%	No

Muchos conjuntos de evaluación no traen toda la evidencia



CON 6.000 TOKENS

44,6%


Musique-Ans:
menos de la mitad.

De 6.000 a 10.000:
sin cambio observado.

RAG ayuda, pero no basta

HotpotQA · proporción dentro de cada subconjunto

■ Correcta ■ Abstención ■ Incorrecta



Con evidencia hay errores; sin ella, **responden más de lo que se abstienen.**

Una pista incompleta *puede ayudar*

01

Conocimiento
previo

02

Pista
parcial

03

Pocas
alternativas

04

Error del
evaluador

Contexto insuficiente $\neq$ contexto inútil.

¿Cómo guiar la decisión de responder?

01 / SELECCIÓN EXTERNA

Generar → filtrar → entregar

Decidir qué respuestas emitir

02 / AJUSTE DEL MODELO


Aprender a decir «no lo sé»

Cambiar el comportamiento al generar

Responder menos, pero elegir mejor

Gemini 1.5 Pro · HotpotQA

■ Confianza ■ Confianza + suficiencia



2-10%

Mejora reportada
entre las respuestas
emitidas

Depende del modelo,
la tarea y la cobertura.

Enseñar «no lo sé» no fue una solución limpia

AJUSTE FINO

Más aciertos en algunos casos.
Persisten los errores.

El equilibrio con la abstención cambia.

ALCANCE DEL ESTUDIO

Preguntas y respuestas textuales

Evaluadores imperfectos

Recuperación sin optimizar

La suficiencia aporta una señal, **no una garantía universal.**

Un RAG confiable necesita tres cosas

01 · Recuperar evidencia

02 · Usar la evidencia

03 · Saber cuándo no alcanza

Gracias. ¿Preguntas?