

cuando un modelo responde mal con los documentos en la mano...

¿No encontró lo necesario, o no supo aprovecharlos?

Sufficient Context: A New Lens on RAG Systems · ICLR 2025

Sebastián Palma Masabeu · IA Generativa · 7 de octubre de 2026




MEMORIA PROPIA

lo que ya sabemos





RAG: recuperar antes de generar



**ocurre en inferencia,
no en entrenamiento**

RAG falla aun con documentos en la mano


1

Responden mal aun
con evidencia
recuperada



2

Se distraen con
información no
relacionada



3

No extraen bien la
respuesta de textos
largos



"Relevante" no es "suficiente"

CONTEXTO (IR) RELEVANTE

Easily Distracted (Shi 2023)

Knowledge Conflicts (Xie 2024)

Ret-Robust (Yoran 2024)

The Power of Noise (Cuconasu 2024)

REDUCIR ALUCINACIONES

Self-RAG (Asai 2023)

Speculative RAG (Wang 2024)

"lost in the middle" (Liu 2024)

hueco: ¿la evidencia permite construir la respuesta?

La definición de contexto suficiente

$$q' = (Q, C)$$

suficiente $\Leftrightarrow \exists A'$ plausible para Q dada C


Q pregunta

C contexto

A' respuesta plausible

suficiente $\neq$ verdadero

Un juez automático de suficiencia



~~respuesta oficial A~~

no la necesita


93% de acuerdo con humanos

115 instancias etiquetadas a mano · PopQA · FreshQA · Natural Questions · EntityQuestions

93%

Método	Exactitud	¿Sin respuesta oficial?
Gemini 1.5 Pro (1-shot)	93,0%	✓
FLAMe (PaLM 24B ajustado)	87,8%	✓
Gemini 1.5 Pro (0-shot)	87,0%	✓
TRUE-NLI (T5 11B)	82,6%	✗
Coincidencia literal (Contains GT)	80,9%	✗

¿Los benchmarks traen la evidencia?



Alucinan más de lo que se abstienen



El giro: aciertan igual sin evidencia

35-62%

de aciertos con contexto
insuficiente

- 1 Pregunta sí/no: 50% por azar
- 2 Opciones limitadas
- 3 Multi-hop: infiere el eslabón
- 4 Multi-hop: pista parcial + memoria
- 5 Demasiados saltos: razona igual
- 6 Ambigua: adivina la interpretación
- 7 Error del autorater
- 8 Ya lo sabía (pre-entrenamiento)

La suficiencia como señal: dos caminos

señal de suficiencia

```
graph TD; A[señal de suficiencia] --> B[GENERACIÓN SELECTIVA]; A --> C[FINE-TUNING];
```

GENERACIÓN SELECTIVA


decidir cuándo entregar la respuesta ·
no modifica el modelo

FINE-TUNING

entrenar con ejemplos "no lo sé" ·
modifica el modelo

Dos señales deciden: ¿respondo o me abstengo?

suficiencia (autorater) + confianza del modelo → regresión logística → umbral
exactitud selectiva (% correcto entre lo respondido)



Enseñar "no lo sé" no salió gratis

Mistral 7B con LoRA · Musique

Variante	Correcta	Abstención	Alucinación
RAG sin ajuste	28,8	11,8	59,4
FT respuestas originales	31,4	0,0	68,6
FT 20% "no lo sé" (aleatorio)	23,0	1,2	75,8
FT 20% "no lo sé" (insuficientes)	23,0	2,2	74,8

La respuesta: pasan las dos cosas

NO ENCONTRÓ — multi-hop: más de la mitad sin evidencia

NO APROVECHÓ — alucinan aun con la evidencia al frente

LA SALIDA — medir la suficiencia y decidir cuándo responder

Gracias — ¿preguntas?

arXiv:2411.06037 · ICLR 2025